

SENTINEL HEALTH

Plataforma Multimodal de Inteligência Artificial
para Monitoramento Contínuo da Saúde da Mulher

TECH CHALLENGE — FASE 4

Grupo Sala 14

Adriana Martins de Souza - RM 368050

Diego Oliveira da Silva - RM 367964

Eduardo Nicola F. Zagari - RM 368021

Renan de Assis Torres - RM 368513

São Paulo

Maio de 2026

Grupo Sala 14

SENTINEL HEALTH

Plataforma Multimodal de Inteligência Artificial para
Monitoramento Contínuo da Saúde da Mulher

Relatório técnico apresentado como parte dos
requisitos para aprovação no Tech Challenge
da Fase 4 do curso de Pós-Graduação em In-
teligência Artificial para Devs da FIAP.

São Paulo

Maio de 2026

Disponibilização do Código e Materiais

Todo o código desenvolvido neste projeto, bem como esta documentação e o link para o vídeo demonstrativo estão disponíveis publicamente em:

GitHub: <https://github.com/Zagari/sentinel-health>

Conteúdo Disponível:

- **Sentinel Surgical** (`modules/surgical/`): código-fonte do pipeline YOLOv8m *fine-tuned* para detecção de sangramento anômalo em cirurgias ginecológicas
- **Sentinel Insight** (`modules/insight/`): código-fonte do pipeline multimodal de análise emocional (DeepFace + Whisper-1 + GPT-5.4-nano)
- **Modelo treinado** publicado no Hugging Face Hub
- **Landing institucional** (`landing/`): página inicial, matriz interativa de cobertura do desafio (`coverage.html` + `coverage-data.json`) e apresentação *reveal.js* de 15 *slides* sincronizada com o roteiro do vídeo
- **Deploy** unificado (`deploy/`): `docker-compose.yml` com 4 contêineres (nginx + 3 módulos) e *override* `docker-compose.behind-proxy.yml` para execução atrás de *reverse proxy* do *host*
- **Infraestrutura como Código** (`terraform/`): módulos AWS (*storage* S3 e *runtime* EC2 `t3.medium` com IAM + SG + EIP) e *environment* demo para *provisioning* em ~\$0,04/h
- Este relatório técnico em PDF (`relatorio/sentinel-health-relatorio-tecnico-fase4.pdf`)

Vídeo demonstrativo: <https://youtu.be/R8rpxGRJ-jY?feature=shared>

BÔNUS – Aplicação temporariamente em Produção para Teste/Experimentação: A aplicação está disponível online em um servidor para demonstração em

<https://sentinel-health.genesis-dataculture.com>

Licença: MIT License (código aberto para fins educacionais e de pesquisa)

Resumo

Este trabalho apresenta o **Sentinel Health**, uma plataforma multimodal de Inteligência Artificial para monitoramento contínuo da saúde da mulher, desenvolvida como entrega do Tech Challenge da Fase 4 do curso de Pós-Graduação em Inteligência Artificial para Devs da FIAP. A plataforma agrega dois módulos especialistas — **Sentinel Surgical** (análise de vídeo cirúrgico) e **Sentinel Insight** (análise emocional de áudio, vídeo e texto de consultas) — orquestrados por um *reverse proxy* nginx e *deployable* via Docker Compose ou Terraform na AWS.

O **Surgical** implementa um modelo YOLOv8m *fine-tuned* em três fases sobre os *datasets* CholecSeg8k (*baseline* em colecistectomia) e GynSurg (*fine-tuning* com 1020 *frames* anotados de laparoscopia ginecológica), alcançando **91,72% de detecção** e **13,44% de falsos positivos** para sangramento anômalo. O modelo é distribuído publicamente no Hugging Face Hub com *model card* profissional. O **Insight** combina DeepFace (análise facial *frame-a-frame*), Whisper-1 (transcrição automática) e GPT-5.4-nano (análise textual) em um *pipeline* multimodal que cobre integralmente os quatro cenários do Requisito de Áudio do desafio (consultas ginecológicas, pré-natal com ansiedade gestacional, pós-parto com depressão, atendimento a vítimas de violência), com *fallback rule-based* de 27 expressões regulares para degradação graciosa quando o LLM está indisponível.

A plataforma integra três provedores de nuvem (AWS para infraestrutura, OpenAI para LLM/ASR, Hugging Face Hub para distribuição do modelo) com práticas rigorosas de privacidade — *secrets* em SSM Parameter Store, SSH desabilitado em favor de SSM Session Manager, *buckets* S3 com *block public access*, sem persistência centralizada de dados de paciente. A cobertura final do desafio é de **21 itens atendidos** dos 23 listados na proposta, com os 2 itens restantes (fisioterapia pós-parto via *pose estimation* e detecção de anomalias em sinais vitais) declarados explicitamente em *roadmap*. O código-fonte é distribuído sob licença MIT em github.com/Zagari/sentinel-health.

Palavras-chave: Inteligência Artificial Multimodal; Saúde da Mulher; YOLOv8; Detecção de Sangramento Cirúrgico; Análise Emocional; Violência Doméstica; LGPD; FIAP.

Abstract

This work presents **Sentinel Health**, a multimodal Artificial Intelligence platform for continuous monitoring of women's health, developed as the deliverable of the Phase 4 Tech Challenge of the postgraduate program in Artificial Intelligence for Developers at FIAP. The platform aggregates two specialist modules — **Sentinel Surgical** (surgical video analysis) and **Sentinel Insight** (multimodal emotion analysis of audio, video and text from medical consultations) — orchestrated by an nginx reverse proxy and deployable via Docker Compose or Terraform on AWS.

Surgical implements a YOLOv8m model fine-tuned in three stages on the CholecSeg8k (cholecystectomy baseline) and GynSurg (fine-tuning with 1020 annotated frames from gynecological laparoscopy) datasets, achieving **91.72% detection rate** with **13.44% false positives** for anomalous bleeding. The model is publicly distributed on Hugging Face Hub with a professional model card. **Insight** combines DeepFace (frame-by-frame facial analysis), Whisper-1 (automatic transcription) and GPT-5.4-nano (textual analysis) in a multimodal pipeline that fully covers the four scenarios of the Audio Requirement (gynecological consultations, prenatal with gestational anxiety, postpartum with depression, support for victims of violence), with a rule-based fallback of 27 weighted regular expressions for graceful degradation when the LLM is unavailable.

The platform integrates three cloud providers (AWS for infrastructure, OpenAI for LLM/ASR, Hugging Face Hub for model distribution) with strict privacy practices — secrets in SSM Parameter Store, SSH disabled in favor of SSM Session Manager, S3 buckets with block public access, no centralized patient data persistence. Final coverage of the challenge is **21 out of 23 items** attended, with the 2 remaining items (postpartum physiotherapy via pose estimation and vital signs anomaly detection) explicitly declared in the roadmap. Source code is distributed under MIT license at github.com/Zagari/sentinel-health.

Keywords: Multimodal Artificial Intelligence; Women's Health; YOLOv8; Surgical Bleeding Detection; Emotion Analysis; Domestic Violence; LGPD; FIAP.

Sumário

Disponibilização do Código e Materiais	i
Resumo	ii
Abstract	iii
Lista de Abreviaturas e Siglas	ix
1 Introdução	1
1.1 Contexto e Motivação	1
1.2 O Desafio	2
1.3 Escopo da Proposta	2
1.4 Organização do Documento	3
2 Fundamentação Teórica	4
2.1 IA Multimodal em Saúde	4
2.2 Detecção de Objetos: YOLOv8	4
2.2.1 Arquitetura	5
2.2.2 Métricas de Avaliação	5
2.3 Análise Facial de Emoções: DeepFace	5
2.4 Reconhecimento Automático de Fala: Whisper	6
2.5 Modelos de Linguagem (LLMs) em Apoio Clínico	6
2.6 Datasets Utilizados	6
2.6.1 CholecSeg8k	6
2.6.2 GynSurg	7
2.6.3 FER2013 (referência para DeepFace)	7
2.7 Considerações Éticas em Saúde da Mulher	7
3 Arquitetura Multimodal	9
3.1 Visão Geral	9
3.2 Diagrama de Componentes	10
3.3 Roteamento e Reverse Proxy	10

3.4	Variantes de Deployment	11
3.4.1	Local	11
3.4.2	Atrás de Proxy Reverso do Host	11
3.4.3	AWS via Terraform	11
3.5	Distribuição do Modelo	12
4	Sentinel Surgical	13
4.1	Escolha do Alvo de Detecção	13
4.2	Datasets	13
4.2.1	CholecSeg8k (baseline)	13
4.2.2	GynSurg (fine-tuning)	14
4.3	Pipeline de Treinamento em Três Fases	14
4.3.1	Fase 1 — Baseline em CholecSeg8k	14
4.3.2	Fase 2 — Peso do Loss de Classificação	14
4.3.3	Fase 3 — Fine-tuning em GynSurg	15
4.4	Threshold de Confiança	15
4.5	Pipeline de Inferência	16
4.6	Interface de Anotação	17
5	Sentinel Insight	18
5.1	Objetivo e Cenários Cobertos	18
5.2	Arquitetura do Pipeline	18
5.3	Três Modos de Operação	19
5.4	Prompt Especializado	19
5.5	Fallback Rule-Based	20
5.6	Visualização e Exportação	21
5.7	Considerações Específicas para Cada Cenário	21
5.7.1	Consultas Ginecológicas	21
5.7.2	Pré-natal	21
5.7.3	Pós-parto	21
5.7.4	Vítimas de Violência	22
6	Infraestrutura, Cloud e LGPD	23
6.1	Estratégia Multi-Cloud	23
6.2	Infraestrutura como Código	23
6.3	Acesso Administrativo via SSM Session Manager	24
6.4	Secrets Management	24
6.5	LGPD: Princípios e Práticas Aplicadas	25
6.5.1	Volumes Locais por Padrão	25
6.5.2	TLS End-to-End	25

6.5.3	Sem Persistência Centralizada de Dados de Paciente	25
6.5.4	Logs Sem PII	25
6.5.5	Princípio do Mínimo Privilégio	26
6.5.6	Princípio do Esquecimento	26
6.6	Estimativa de Custos	26
7	Resultados e Discussão	27
7.1	Matriz de Cobertura do Desafio	27
7.2	Resultados Quantitativos do Surgical	28
7.2.1	Discussão da Taxa de FP	28
7.3	Resultados Qualitativos do Insight	28
7.4	Exemplo Representativo: Análise de Vídeo de Sangramento	29
7.5	Exemplo Representativo: Análise de Áudio com Sinais de Violência	30
7.6	Bug Fixes Notáveis Durante o Desenvolvimento	30
7.6.1	yt-dlp e o Player do YouTube	30
7.6.2	Cloudflare 524 por Bloqueio do Event Loop	30
7.6.3	License Detection do GitHub	30
7.7	Limitações Conhecidas	31
7.8	Discussão Sobre Uso Responsável	31
8	Conclusões e Roadmap	32
8.1	Síntese do Trabalho	32
8.2	Atendimento ao Desafio	33
8.3	Roadmap	34
8.3.1	Sentinel Motion	34
8.3.2	Sentinel VitalSigns	34
8.3.3	Sentinel Realtime	34
8.3.4	Sentinel Pose	34
8.4	Recomendações para Evolução Responsável	35
8.5	Agradecimentos	35
	Referências Bibliográficas	36

Lista de Figuras

- 3.1 Topologia da plataforma Sentinel Health. Quatro containers orquestrados por `docker-compose`, com `nginx` fazendo roteamento por *path*. Integração com três provedores de nuvem: AWS (infraestrutura), OpenAI (LLM/ASR) e Hugging Face Hub (distribuição do modelo treinado). 10

Lista de Tabelas

4.1	Evolução das métricas ao longo das três fases de treinamento do YOLOv8m. Métricas medidas em conjunto de validação de 20 clipes (1.800 <i>frames</i>) de laparoscopia ginecológica do GynSurg.	14
4.2	<i>Threshold sweep</i> no modelo v3 <i>fine-tuned</i> . Valores de detecção e FP em pontos percentuais.	16
6.1	Estimativa de custos para <i>deploy</i> demonstrativo de 1 hora (AWS us-east-1, preços <i>on-demand</i> 2026).	26
7.1	Cobertura do Tech Challenge Fase 4 pelo Sentinel Health (agregada por seção do enunciado).	27
7.2	Resultados consolidados do Sentinel Surgical (v3 <i>fine-tuned</i> em GynSurg, <i>threshold</i> 0,30, conjunto de validação de 20 clipes com 1.800 <i>frames</i>).	28
7.3	Avaliação qualitativa do Sentinel Insight em 12 áudios sintéticos. <i>Ground truth</i> estabelecido pelo grupo a partir do roteiro do áudio gerado.	29
7.4	Excerto do JSON de detecções para um clipe representativo. Resumo: <code>total_detections=37, duration=8s, detections_by_class={blood: 37}</code>	29
8.1	Atendimento ao Tech Challenge Fase 4 — síntese final.	33

Lista de Abreviaturas e Siglas

API Application Programming Interface. 10, 20, 21, 25, 31

ASR Automatic Speech Recognition. vi, 1, 10, 23

AWS Amazon Web Services. 3, 23, 24

CV Computer Vision. 1, 7

DPO Data Protection Officer. 26

EC2 Elastic Compute Cloud. 11, 23–26, 28

EHR Electronic Health Record. 19, 21, 25, 31

FER Facial Emotion Recognition. 5, 7

FN Falso Negativo. 5

FP Falso Positivo. vii, 5, 14–16, 28, 31

HF Hugging Face. 3, 12

IA Inteligência Artificial. 1

IaC Infrastructure as Code. 3, 11, 23

IoU Intersection over Union. 5

LGPD Lei Geral de Proteção de Dados. 3, 7, 23, 25, 26, 32

LLM Large Language Model. vi, 1, 6, 10, 18, 19, 23, 28

mAP mean Average Precision. 5

MIT Massachusetts Institute of Technology. 30

S3 Simple Storage Service. 11, 12, 23, 24, 26

SSM Systems Manager. 11, 23, 24, 32

SSO Single Sign-On. 24

STT Speech-to-Text. 6

TLS Transport Layer Security. 10, 11, 25

UI User Interface. 9, 10, 19, 21, 31, 34

VPS Virtual Private Server. 11

YOLO You Only Look Once. 4

Introdução

1.1 Contexto e Motivação

A saúde da mulher engloba domínios clínicos com particularidades fisiológicas, emocionais e sociais que historicamente recebem menor atenção em pesquisa biomédica e em ferramentas de apoio à decisão clínica ([World Health Organization, 2024](#)). Cirurgias ginecológicas e obstétricas, monitoramento pré e pós-natal, atendimento a vítimas de violência doméstica e suporte ao bem-estar psicológico feminino concentram, simultaneamente, alto volume de dados multimodais (vídeo, áudio, exames, prontuários) e baixa cobertura por sistemas automatizados especializados.

Com o avanço de modelos de Inteligência Artificial (IA) multimodal — capazes de processar vídeo, áudio e texto em *pipelines* integrados — surge a oportunidade de complementar a equipe clínica com camadas adicionais de detecção precoce de risco, alertas em tempo quase real e análises agregadas longitudinais. Iniciativas recentes em Computer Vision (CV) aplicada a vídeo cirúrgico ([Kletz; Schoeffmann; Husslein, 2019](#)), em Automatic Speech Recognition (ASR) robusto ([Radford et al., 2022](#)), e em Large Language Model (LLM) ajustados para domínio clínico ([Singhal; Azizi et al., 2023](#)) demonstram que a tecnologia já está madura para protótipos integrados — embora a passagem para uso clínico real exija validação rigorosa que vai muito além do escopo de um trabalho acadêmico.

Importante

Este trabalho apresenta um **protótipo acadêmico**. O Sentinel Health **não é um dispositivo médico**, não foi submetido a validação clínica, e **não deve ser usado para decisões diagnósticas, terapêuticas ou de suporte a vítimas em situação real**. Os modelos foram treinados em *datasets* de pesquisa com vieses conhecidos. Qualquer interpretação dos resultados requer profissionais de saúde qualificados.

1.2 O Desafio

O Tech Challenge da Fase 4 do curso de Pós-Graduação em Inteligência Artificial para Devs da FIAP propõe estender o sistema multimodal hospitalar para monitoramento contínuo de pacientes do sexo feminino, com foco em sinais precoces de risco específicos da saúde e segurança da mulher. O enunciado oferece quatro frentes de funcionalidade, das quais a proposta deve atender pelo menos duas:

- Análise de vídeos de partos, cirurgias ginecológicas, sessões de fisioterapia pós-parto e consultas, em busca de padrões anômalos ou sinais de desconforto.
- Processamento de gravações de voz de pacientes em consultas, detectando sintomas relacionados à fala (depressão pós-parto, ansiedade, sinais de violência doméstica, fadiga hormonal).
- Detecção de anomalias em sinais vitais específicos (pressão arterial em gestantes, batimentos fetais), prescrições hormonais e evolução clínica, com alertas para equipe especializada.
- Integração com serviços gerenciados em nuvem, com requisitos rigorosos de privacidade e segurança para dados sensíveis.

Cinco objetivos são listados, dos quais a proposta deve atender pelo menos três: detecção precoce de riscos materno-ginecológicos; identificação de sinais de violência ou abuso; monitoramento de bem-estar psicológico feminino; uso de nuvem para processamento especializado; detecção de anomalias em tempo real para monitoramento preventivo.

Como entregas técnicas obrigatórias, o desafio define dois requisitos centrais: **Análise de Vídeo Especializada**, incluindo um modelo YOLOv8 customizado para um alvo específico (instrumentos, áreas críticas, sangramento anômalo ou objetos suspeitos) e relatórios automáticos de desvios, complicações e indicadores; e **Análise de Áudio Especializada** de consultas médicas, cobrindo cenários ginecológicos, pré-natal, pós-parto e atendimento a vítimas. Os entregáveis são repositório Git aberto, relatório técnico (este documento) e vídeo demonstrativo de até 15 minutos.

1.3 Escopo da Proposta

A entrega do grupo **atende três funcionalidades e os cinco objetivos**, excedendo os mínimos das duas seções com opção. A cobertura completa item a item está formalizada no Capítulo 7 e na matriz interativa disponível em `coverage.html` dentro da plataforma.

A solução proposta — denominada **Sentinel Health** — agrega dois módulos especialistas orquestrados em uma plataforma única:

- **Sentinel Surgical:** detecção de sangramento anômalo em cirurgias ginecológicas por meio de um YOLOv8m *fine-tuned* (Capítulo 4). Atende o Requisito de Vídeo do desafio.
- **Sentinel Insight:** análise emocional multimodal (face + voz + texto) de consultas, com prompt especializado em saúde da mulher, cobrindo violência doméstica, ansiedade gestacional, depressão pós-parto e atendimento ginecológico (Capítulo 5). Atende integralmente o Requisito de Áudio.

Os módulos compartilham infraestrutura de *deployment* (Docker Compose local ou Terraform na AWS), *reverse proxy* nginx e *landing page* institucional, com integração a três provedores de nuvem (Capítulo 6). Os 2 itens não atendidos do enunciado — análise de fisioterapia pós-parto e detecção de anomalias em sinais vitais — são declarados explicitamente em *roadmap* (Capítulo 8), com tecnologias-alvo e justificativa de priorização.

1.4 Organização do Documento

O restante deste documento está estruturado da seguinte forma:

- O **Capítulo 2** apresenta a fundamentação teórica das tecnologias utilizadas — YOLOv8, DeepFace, Whisper, LLMs e o ecossistema multimodal em saúde — junto com considerações éticas específicas para o domínio.
- O **Capítulo 3** descreve a arquitetura geral da plataforma Sentinel Health, com diagrama de componentes, fluxos de dados e estratégias de *deployment*.
- Os **Capítulos 4 e 5** detalham, respectivamente, os módulos Surgical e Insight: *datasets*, *pipeline* de treinamento, *prompt engineering*, integração de modalidades e resultados isolados.
- O **Capítulo 6** consolida a integração com nuvem (AWS, OpenAI, HF Hub), IaC via Terraform e as práticas de privacidade alinhadas à Lei Geral de Proteção de Dados (LGPD).
- O **Capítulo 7** apresenta a matriz de cobertura do desafio, resultados agregados, exemplos de detecções e a discussão crítica das limitações observadas.
- O **Capítulo 8** sintetiza as contribuições, declara as quatro frentes de *roadmap* e fecha com recomendações para evolução responsável.

Fundamentação Teórica

Este capítulo apresenta as bases teóricas e as tecnologias utilizadas pelos dois módulos do Sentinel Health. A descrição é deliberadamente concisa, focando nos conceitos necessários para acompanhar as decisões de projeto dos capítulos seguintes; referências bibliográficas indicam a literatura completa para aprofundamento.

2.1 IA Multimodal em Saúde

Sistemas multimodais combinam diferentes tipos de sinal — vídeo, áudio, texto, dados tabulares, séries temporais — em *pipelines* cujo objetivo é gerar uma representação ou decisão que nenhuma modalidade isolada produziria com igual qualidade ([Baltrušaitis; Ahuja; Morency, 2019](#)). No domínio clínico, essa abordagem é particularmente promissora para cenários em que sinais complementares aumentam a robustez do diagnóstico: por exemplo, um sintoma relatado pela paciente (texto/voz), corroborado por expressão facial (vídeo) e exame complementar (imagem médica) eleva a confiança da inferência muito além da fala isolada.

A arquitetura multimodal do Sentinel Health adota o padrão de **fusão tardia** (*late fusion*) ([Snoek; Worring; Smeulders, 2005](#)): cada modalidade é processada por um modelo especializado, e a integração ocorre no nível das pontuações ou decisões finais. Essa escolha sacrifica algum potencial de captura de correlações cruzadas — possível em *early fusion* ou *joint embedding* — em troca de modularidade, interpretabilidade e capacidade de degradação graciosa quando uma modalidade está indisponível.

2.2 Detecção de Objetos: YOLOv8

A família You Only Look Once (YOLO) introduziu uma mudança paradigmática na detecção de objetos ao formular a tarefa como uma única regressão em vez do pipeline tradicional de proposta de regiões seguida por classificação ([Redmon et al., 2016](#)). A versão **YOLOv8** ([Jocher; Chaurasia; Qiu, 2023](#)), desenvolvida pela Ultralytics e lançada em 2023, consolida várias

melhorias arquiteturais e de *training pipeline* acumuladas nas versões intermediárias.

2.2.1 Arquitetura

YOLOv8 organiza-se em três blocos: **backbone** (extração hierárquica de *features* via CSP-Darknet), **neck** (agregação multi-escala via PAN-FPN) e **head** (regressão de *bounding boxes*, classificação e confiança). A versão $\mathfrak{m}$ (*medium*) — escolhida neste trabalho — totaliza aproximadamente 25,9 milhões de parâmetros, equilibrando custo computacional e precisão.

2.2.2 Métricas de Avaliação

A avaliação de detectores em saúde clínica requer cuidado: as métricas padrão de *Computer Vision* (mean Average Precision (mAP), Intersection over Union (IoU)) são úteis mas insuficientes quando o custo de Falso Positivo (FP) e Falso Negativo (FN) é assimétrico, como em sangramento cirúrgico. Neste trabalho, complementamos mAP/IoU com:

- **Taxa de detecção:** porcentagem de cliques com sangramento (*ground truth* positivo) em que o modelo detecta ao menos uma ocorrência.
- **Taxa de FP:** porcentagem de cliques sem sangramento em que o modelo gera ao menos uma detecção espúria.

Essas métricas operacionais — orientadas a casos clínicos por clipe e não a IoU por *frame* — refletem melhor o uso real (alerta acionável por evento) do que métricas agregadas.

2.3 Análise Facial de Emoções: DeepFace

Facial Emotion Recognition (FER) é a tarefa de classificar imagens faciais em categorias emocionais discretas (tipicamente *angry, disgust, fear, happy, sad, surprise, neutral*). O **DeepFace** (Serengil; Ozpinar, 2020) é uma *framework* Python que envolve modelos pré-treinados (VGG-Face, Facenet, OpenFace, ArcFace, entre outros) com uma API simples para detecção facial, reconhecimento e classificação emocional.

A abordagem do Sentinel Insight é processar cada *frame* de vídeo individualmente, agregar predições em janela deslizante, e expor as proporções emocionais como *features* para o LLM combinador final. Limitações conhecidas do FER clássico — dependência de iluminação, viés racial dos *datasets* de treino (Buolamwini; Gebru, 2018), baixa generalização para faces parcialmente ocluídas ou em ângulos extremos — são reconhecidas e abordadas como *caveats* na interpretação dos resultados.

2.4 Reconhecimento Automático de Fala: Whisper

O **Whisper** (Radford et al., 2022), lançado pela OpenAI em 2022, é um modelo *encoder-decoder transformer* treinado em 680.000 horas de áudio multilíngue rotulado coletado da *web*. Sua robustez ao ruído, alcance multilíngue (99 idiomas incluindo português brasileiro) e suporte nativo a tradução, segmentação temporal e detecção de idioma fazem dele o estado da arte aberto em Speech-to-Text (STT).

No Sentinel Insight, utilizamos o endpoint `whisper-1` da API da OpenAI (variante *large-v2* hospedada) para transcrição de áudio de consultas. A transcrição é então passada como contexto para o LLM analisador, em vez de servir apenas como saída isolada — permitindo análise pragmática (intenção, sentimento, sinais de risco) sobre o texto reconhecido.

2.5 Modelos de Linguagem (LLMs) em Apoio Clínico

Large Language Model (LLM) ajustados ou *prompted* para domínio clínico têm demonstrado capacidade crescente de extrair informação estruturada de relatos não estruturados (Singhal; Azizi et al., 2023; Singhal; Tu et al., 2023). As limitações são bem documentadas: alucinações (Ji et al., 2023), vieses do corpus de treino, sensibilidade a *prompt*, e tendência à *sycophancy*. Em uso clínico real, o uso seguro de LLM requer *guardrails*, *human-in-the-loop* obrigatório e validação prospectiva.

O Sentinel Insight utiliza o `gpt-5.4-nano` via API da OpenAI como *combinador* final: recebe a transcrição do áudio, opcionalmente as proporções emocionais do DeepFace, e produz uma análise estruturada em JSON com campos `sentiment`, `risk_level`, `detected_signals`, `keywords`, `domestic_violence_signals` e `recommended_action`. O *prompt* é especializado para os quatro cenários do Requisito de Áudio do desafio (ver Capítulo 5).

2.6 Datasets Utilizados

2.6.1 CholecSeg8k

O **CholecSeg8k** (Hong et al., 2020) é um *dataset* público de 8.080 *frames* anotados de cirurgia laparoscópica de *colecistectomia* (remoção da vesícula biliar). Cada *frame* é segmentado em 13 classes (*Black Background*, *Abdominal Wall*, *Liver*, *Gastrointestinal Tract*, *Fat*, *Grasper*, *Connective Tissue*, *Blood*, *Cystic Duct*, *L-Hook Electrocautery*, *Gallbladder*, *Hepatic Vein*, *Liver Ligament*). Foi utilizado como **baseline de pré-treinamento** pela disponibilidade de máscaras de *Blood* já anotadas, mesmo em domínio cirúrgico diferente.

2.6.2 GynSurg

O **GynSurg** ([GynSurg Dataset Contributors, 2023](#)) é um *dataset* de vídeo laparoscópico ginecológico — domínio-alvo deste trabalho. Para a fase de *fine-tuning* foram **anotados manualmente 1020 frames** pelo grupo, derivados de clipes representativos do *dataset* bruto, marcando ocorrências de sangramento anômalo. A interface de anotação semi-supervisionada utilizada neste processo é descrita no Capítulo 4.

2.6.3 FER2013 (referência para DeepFace)

O **FER2013** ([Goodfellow et al., 2013](#)) é o *dataset* de referência usado em parte dos modelos suportados pelo DeepFace: 35.887 imagens em escala de cinza 48×48 organizadas em sete classes emocionais. Apesar de pequeno e enviesado pela origem (rostos extraídos da *web* com viés ocidental e demográfico), permanece o *benchmark* mais comum em FER. Não realizamos *re-training* sobre FER2013; usamos os pesos pré-treinados do DeepFace diretamente.

2.7 Considerações Éticas em Saúde da Mulher

A aplicação de IA em saúde da mulher carrega responsabilidades éticas adicionais às de aplicações clínicas gerais:

- **Viés de *dataset*:** *datasets* médicos têm historicamente sub-representação de pacientes femininas em pesquisa cardiovascular, oncológica e em estudos de medicamentos ([Liu; Mager, 2016](#)). Modelos de CV treinados em populações pouco diversas podem ter desempenho desigual entre grupos demográficos.
- **Detecção de violência doméstica:** alertar erroneamente é tão danoso quanto falhar em alertar. Falsos positivos podem expor a vítima a riscos adicionais se a triagem for visível ao agressor; falsos negativos perpetuam o ciclo de violência. O sistema é desenhado para **registro confidencial** e **revisão por profissional treinado**, nunca para ação automatizada.
- **Depressão pós-parto e ansiedade gestacional:** sinais detectados são **indicadores** para investigação clínica humana, não diagnóstico. A literatura é clara quanto ao papel insubstituível da escuta qualificada por profissional treinado ([Howard; Khalifeh, 2020](#)).
- **Conformidade legal e regulatória:** dados de saúde da mulher são particularmente sensíveis sob a Lei Geral de Proteção de Dados (LGPD), exigindo base legal específica, finalidade explícita e direito à eliminação. As práticas adotadas neste protótipo são detalhadas no Capítulo 6.

Atenção

Nenhum dos modelos descritos neste documento foi submetido a validação clínica em ambiente real. As métricas reportadas referem-se a conjuntos de validação de pesquisa, com vieses conhecidos e *caveats* de generalização declarados. O uso responsável requer profissional de saúde qualificado em todas as etapas.

Arquitetura Multimodal

Este capítulo descreve a arquitetura da plataforma **Sentinel Health** sob a ótica de componentes, fluxos de dados e estratégias de *deployment*. O detalhamento técnico de cada módulo está nos Capítulos 4 (Surgical) e 5 (Insight); aqui, o foco é a visão integrada.

3.1 Visão Geral

O Sentinel Health adota o padrão de **monorepo orquestrado por containers**: cada módulo é um serviço Docker independente, com seu próprio *stack* (linguagem, dependências, modelo), exposto atrás de um único *reverse proxy* nginx. Quatro containers compõem o *stack* de produção:

1. `nginx` — *reverse proxy*; roteia por *path* (`/`, `/surgical/`, `/insight/`, `/coverage.html`, `/presentation/`).
2. `landing` — *site* estático servido por `nginx-alpine`; *landing page*, página de cobertura do desafio (interativa com filtros) e apresentação *reveal.js*.
3. `surgical` — FastAPI + YOLOv8m; User Interface (UI) de *upload* e processamento de vídeo cirúrgico.
4. `insight` — Streamlit; UI de análise emocional multimodal (face + voz + texto).

A escolha de monorepo (em vez de repositórios separados por módulo) foi deliberada: facilita a coordenação de versões compatíveis entre serviços, simplifica a estratégia de *deploy* (um único `docker-compose up`) e produz uma matriz de cobertura única e consistente em relação ao desafio. O preço pago é maior tamanho do repositório; mitigado por `.gitignore` estrito que exclui artefatos pesados (vídeos, *datasets* brutos, *checkpoints*).

3.2 Diagrama de Componentes

A Figura 3.1 apresenta a topologia do *stack*, mostrando os quatro containers, os *paths* servidos pelo nginx, e as integrações de nuvem externas.




Figura 3.1: Topologia da plataforma Sentinel Health. Quatro containers orquestrados por docker-compose, com nginx fazendo roteamento por *path*. Integração com três provedores de nuvem: AWS (infraestrutura), OpenAI (LLM/ASR) e Hugging Face Hub (distribuição do modelo treinado).

3.3 Roteamento e Reverse Proxy

O nginx serve como ponto único de entrada (*single point of entry*), simplificando a configuração de Transport Layer Security (TLS), política de *cross-origin*, *logging* centralizado e versionamento de API. O arquivo de configuração `nginx/sentinel.conf` define um servidor virtual que mapeia *paths* para *upstreams* internos:

- `/` → `landing:80` (HTML estático)
- `/surgical/` → `surgical:8000` (FastAPI)
- `/insight/` → `insight:8501` (Streamlit)
- `/api/` → `surgical:8000/api/` (endpoints REST do Surgical)
- `/static/` → `surgical:8000/static/` (CSS/JS do Surgical)

A configuração inclui *WebSocket upgrade* (`map $http_upgrade $connection_upgrade`) necessário para o Streamlit do Insight, que estabelece canal bidirecional para atualização reativa da UI. O `STREAMLIT_SERVER_BASE_URL_PATH=/insight` é configurado no container Insight para que o *framework* gere URLs relativas corretas atrás do proxy.

3.4 Variantes de Deployment

A mesma *stack* suporta três cenários de *deployment*, todos via `docker-compose`:

3.4.1 Local

```
1 cd deploy
2 docker compose up -d
3 open http://localhost/
```

Listing 3.1: Subindo o stack localmente

Atende desenvolvimento individual e demonstração offline. O `nginx` do container publica diretamente na porta 80 do *host*.

3.4.2 Atrás de Proxy Reverso do Host

Em servidores onde o *host* já tem `nginx` ocupando portas 80/443 — caso típico de VPS multi-subdomínio — uma sobreposição (*override*) de *compose* substitui o *binding* para 127.0.0.1:8100, e um *snippet* de configuração `nginx` pronto (`nginx/host-snippet.conf`) faz o *proxy* reverso no *host*, terminando TLS.

```
1 docker compose -f docker-compose.yml \
2                 -f docker-compose.behind-proxy.yml up -d
```

Listing 3.2: Subindo atrás de reverse proxy do host

3.4.3 AWS via Terraform

Para *deploy* demonstrativo em nuvem, o diretório `terraform/` contém IaC completo: S3 *buckets* de *assets*, instância EC2 `t3.medium` com SSM Session Manager (SSH desabilitado por design), IAM Role mínima e `user_data` que clona o repositório e sobe o *stack*.

```
1 cd terraform/environments/demo
2 AWS_PROFILE=<profile> terraform init
3 AWS_PROFILE=<profile> terraform apply
4 # Custo estimado: ~$0.04/h (t3.medium). Lembre-se de destroy
   depois.
```

Listing 3.3: Deploy AWS via Terraform

A separação `modules/storage/`, `modules/runtime/`, `environments/demo/` segue a recomendação de Terraform de modularizar por *layer* de responsabilidade.

3.5 Distribuição do Modelo

O *checkpoint* treinado do Surgical (`best.pt`, 50 MB) é distribuído publicamente no **Hugging Face Hub** sob o repositório `zagari/sentinel-surgical-yolov8m-bleeding`, com *model card* profissional documentando *dataset*, métricas, exemplos de uso e limitações. Esta escolha — em vez de *checkpoint* dentro do S3 *bucket* próprio — traz três benefícios:

1. **Sem credenciais necessárias** no *startup* do container, simplificando o *bootstrap* em ambientes restritos.
2. **Distribuição pública** (alinhada ao espírito acadêmico do projeto) com *model card* explorável.
3. **Versionamento** via tags Git do próprio HF — futuras versões coexistem sem invalidar *checkpoints* anteriores.

O `entrypoint.sh` do container Surgical detecta ausência de `best.pt` em `/app/models/` no primeiro *boot* e baixa automaticamente do HF via `curl`. Subsequentes *boots* encontram o arquivo em *volume* e pulam o *download*.

Sentinel Surgical

Este capítulo detalha o módulo **Sentinel Surgical**, responsável pela análise de vídeo cirúrgico ginecológico, com foco em detecção de sangramento anômalo durante procedimentos laparoscópicos.

4.1 Escolha do Alvo de Detecção

O enunciado do desafio oferece quatro alvos possíveis para o YOLOv8 customizado: instrumentos cirúrgicos ginecológicos, áreas críticas (útero, ovários, mamas), sangramento anômalo durante procedimentos, ou objetos suspeitos indicativos de automutilação. A escolha do grupo foi **sangramento anômalo**, motivada por três fatores:

- **Impacto clínico direto:** sangramento intraoperatório é evento adverso documentado em literatura ginecológica ([Stevens](#); [Salmons](#); [Goldenberg, 2019](#)) com janela curta para intervenção. Detecção precoce automatizada agrega valor real ao fluxo cirúrgico.
- **Disponibilidade de *datasets*:** a classe *Blood* já é anotada em CholecSeg8k, permitindo *transfer learning* de domínio adjacente (colecistectomia laparoscópica) para o domínio-alvo (laparoscopia ginecológica).
- **Generalizabilidade:** um detector de sangramento treinado em ginecologia tem potencial de extensão para outras especialidades laparoscópicas, ampliando o impacto.

4.2 Datasets

4.2.1 CholecSeg8k (baseline)

Conforme apresentado na Seção 2.6 (Fundamentação), o CholecSeg8k oferece 8.080 *frames* anotados em 13 classes, incluindo *Blood*. Como o domínio é cirurgia de vesícula (não ginecologia), a generalização direta não era esperada — daí o uso como *baseline* de pré-treinamento, com fine-tuning subsequente em GynSurg.

4.2.2 GynSurg (fine-tuning)

O *dataset* GynSurg foi usado em sua forma bruta como fonte de clipes representativos de laparoscopia ginecológica. Para o *fine-tuning*, o grupo **anotou manualmente 1020 frames** extraídos de clipes representativos, marcando *bounding boxes* de sangramento anômalo em formato YOLO (`class_id x_center y_center width height`, todos normalizados em $[0, 1]$).

A anotação foi feita em uma interface semi-supervisionada desenvolvida internamente: o modelo da Fase 2 do *pipeline* (`v2_class_weight`) propunha *bounding boxes* candidatas, que o anotador podia aceitar, rejeitar ou corrigir. Esta abordagem reduziu o tempo de anotação em aproximadamente 60% comparado à anotação *from scratch*, sem comprometer a qualidade do *ground truth* (validação cruzada por dois anotadores independentes em amostra de 100 *frames*).

4.3 Pipeline de Treinamento em Três Fases

A estratégia de *transfer learning* adotada consiste em três fases sequenciais, cada uma atacando uma limitação específica observada na anterior. A Tabela 4.1 sumariza a evolução.

Tabela 4.1: Evolução das métricas ao longo das três fases de treinamento do YOLOv8m. Métricas medidas em conjunto de validação de 20 clipes (1.800 *frames*) de laparoscopia ginecológica do GynSurg.

Versão	Estratégia de Treino	Detecção (%)	FP (%)
v1 <i>baseline</i>	CholecSeg8k, 100 épocas	5,41	76,11
v2 <i>cls loss boost</i>	+ peso do <i>loss</i> de classificação <code>cls=3.0</code>	12,14	46,89
v3 <i>fine-tuned</i>	+ 1020 frames GynSurg	91,72	13,44

4.3.1 Fase 1 — Baseline em CholecSeg8k

YOLOv8m foi treinado por 100 épocas sobre CholecSeg8k convertido para formato de detecção (*bounding boxes* derivadas das máscaras de segmentação da classe *Blood*). Hiperparâmetros padrão da Ultralytics: `imgsz=640, batch=16, lr0=0.01`, otimizador SGD. Resultado: detecção de apenas 5,41% — o modelo praticamente ignorava a classe *Blood* por desbalanceamento severo (a maioria dos *frames* contém pouco ou nenhum pixel de *Blood*, e em vídeo o desbalanceamento é amplificado pela redundância temporal entre *frames* consecutivos).

4.3.2 Fase 2 — Peso do Loss de Classificação

Repetição do treino, agora aumentando o peso do *loss* de classificação no *loss* total.

Cabe um esclarecimento sobre o hiperparâmetro. O *loss* de treino do YOLOv8 é uma combinação ponderada de três componentes:

- *box* — regressão de *bounding boxes* (padrão 7,5).
- *cls* — classificação (padrão 0,5).
- *dfl* — *distribution focal loss* (padrão 1,5).

Configurando *cls*=3.0, amplia-se em $6\times$ o peso do termo de classificação em relação ao padrão, forçando o otimizador a priorizar acertos de classe sobre precisão da *bounding box* — útil quando a classe rara está sendo essencialmente ignorada.

cls=3.0 vs. class weighting clássico

O hiperparâmetro *cls* da Ultralytics não é um peso *por classe* (como o *class_weight* do scikit-learn, que multiplica o erro de cada amostra pelo inverso da frequência da sua classe). É um peso do *termo de loss de classificação* no *loss* total multi-tarefa. O efeito prático endereça o mesmo problema (desbalanceamento favorecendo a classe majoritária), mas pelo mecanismo de mudar a importância relativa das sub-tarefas, não pela ponderação por classe individual. Alternativas teriam sido *focal loss* (*f1_gamma*), *oversampling* da classe rara ou *undersampling* da majoritária — todas atacando a mesma raiz por ângulos distintos.

Detecção subiu para 12,14% e FP caiu pela metade (76% → 47%). Sinal claro de que o modelo *podia* aprender o conceito, mas precisava de mais dados do domínio-alvo.

4.3.3 Fase 3 — Fine-tuning em GynSurg

Os 1020 *frames* anotados de GynSurg foram divididos 80/20 em *train/val*, e o modelo da Fase 2 foi *fine-tunado* por 50 épocas adicionais com *lr*=0.001 ($10\times$ menor para preservar pesos pré-treinados). Resultado: **salto de 12% para 91,72% de detecção**, com FP caindo de 47% para 13,44%.

4.4 Threshold de Confiança

A escolha do *threshold* de confiança é decisão crítica em contexto cirúrgico: **perder um sangramento real é muito mais grave do que gerar um alerta falso**. A Tabela 4.2 mostra o *sweep* realizado.

O ponto de operação escolhido foi **0,30**: maximiza sensibilidade (91,72%) mantendo FP em patamar gerenciável (13,44%). Um trade-off racional para o caso de uso — em sala cirúrgica com cirurgiã supervisionando, é preferível um alerta a mais do que perder um evento real.

Tabela 4.2: *Threshold sweep* no modelo v3 *fine-tuned*. Valores de detecção e FP em pontos percentuais.

Threshold	Detecção (%)	FP (%)
0,10	94,48	19,33
0,20	93,05	14,78
0,30 (default)	91,72	13,44
0,50	88,96	9,33
0,70	85,76	4,89

4.5 Pipeline de Inferência

A inferência em vídeo é orquestrada pelo módulo Python VideoDetector (app/services/detector.py). O fluxo:

1. **Abertura** via OpenCV (cv2.VideoCapture).
2. **Iteração** *frame-a-frame*; cada *frame* passa por YOLOv8m (`model.predict(frame, conf=0.30)`).
3. **Renderização**: *bounding boxes* dourados desenhados sobre cada *frame* positivo, com *label* de confiança.
4. **Saída**: novo arquivo MP4 anotado + JSON com *schema* `{job_id, summary: {total_detections, duration_seconds, detections_by_class}, detections: [{frame_index, timestamp, bbox, confidence}, ...]}`.
5. **Callback de progresso**: o detector chama `progress_callback(percent)` a cada *frame*, atualizando o *dict* de *jobs* consumido pelo *endpoint* `/api/video/status/`.

A API REST do Surgical expõe três entradas equivalentes:

- POST `/api/video/upload` — *upload* direto de arquivo MP4/AVI/MOV/MKV/WebM.
- POST `/api/video/url` — URL externa (YouTube, Vimeo, link direto); *yt-dlp* cuida do *download* em *background task* sincronizada com *thread pool* (ver discussão em Capítulo 7).
- POST `/api/samples/process/{category}/{filename}` — clipe pré-carregado da galeria local com *ground truth* conhecido, ideal para demonstração e validação.

Todos os três entram no mesmo *pipeline* de inferência; o usuário acompanha via *polling* de GET `/api/video/status/{job_id}` e baixa o resultado em GET `/api/video/result/{job_id}/{video|report}`.

4.6 Interface de Anotação

A interface semi-supervisionada de anotação (`static/annotation.html`) — desenvolvida para acelerar a Fase 3 — permanece embutida no produto como ferramenta auxiliar para futuro *re-training*:

- Carrega *frame* aleatório de pool de vídeos não anotados.
- Mostra propostas do modelo atual (*bounding boxes* sobre o *frame*).
- Anotador aceita, corrige (arrasta cantos) ou rejeita; em qualquer caso, o resultado é exportado em formato YOLO.
- *Endpoint* `POST /api/annotation/annotate` grava o YOLO TXT em `labels/` pareado com o *frame* em `images/`.

Esta funcionalidade não é parte do fluxo de demonstração mas demonstra o ciclo virtuoso de melhoria contínua que viabiliza o sistema em produção.

Sentinel Insight

Este capítulo detalha o módulo **Sentinel Insight**, responsável pela análise emocional multi-modal de consultas médicas — combinando face, voz e texto — com foco em cenários específicos do Requisito de Áudio do desafio: consultas ginecológicas, pré-natal com ansiedade gestacional, pós-parto com depressão e atendimento a vítimas de violência.

5.1 Objetivo e Cenários Cobertos

O Requisito 2 do enunciado (*Análise de Áudio Especializada para Saúde da Mulher*) lista quatro cenários clínicos:

1. **Consultas ginecológicas:** tom de voz, hesitação ao relatar sintomas.
2. **Acompanhamento pré-natal:** sinais de ansiedade gestacional.
3. **Consultas pós-parto:** detecção precoce de depressão pós-parto.
4. **Atendimento a vítimas de violência:** padrões vocais indicativos de trauma.

O Insight cobre os **quatro cenários integralmente** por meio de um único *pipeline* parametrizado pelo *prompt* do LLM analisador (descrito na Seção 5.4), evitando a fragmentação em quatro detectores independentes que seriam difíceis de manter coerentemente.

5.2 Arquitetura do Pipeline

O Insight implementa o padrão de *late fusion* mencionado no Capítulo 2: três modalidades processadas em paralelo, com integração no nível das saídas de cada modalidade.

1. **Face** (DeepFace) — *frame-a-frame* sobre vídeo, gera proporções de sete emoções básicas (*angry, disgust, fear, happy, sad, surprise, neutral*) e séries temporais.

2. **Voz** (Whisper-1) — transcrição completa do áudio em português brasileiro, com *timestamps* por segmento.
3. **Texto** (GPT-5.4-nano) — análise semântica do texto transcrito, com *prompt* especializado em sinais de risco clínico relevantes para saúde da mulher.

A combinação acontece dentro do *prompt* do LLM, que recebe — no mesmo *turn* — a transcrição do áudio e (opcionalmente) o histograma agregado de emoções faciais. A saída é um JSON estruturado pronto para ingestão em Electronic Health Record (EHR) ou para acionar alertas.

5.3 Três Modos de Operação

A UI Streamlit expõe três modos de entrada, todos resultando no mesmo JSON de saída:

- **Vídeo completo:** *upload* de MP4/AVI/MOV; o sistema extrai áudio com ffmpeg, transcreve via Whisper, analisa face *frame-a-frame* com DeepFace, e combina via GPT.
- **Audio only:** *upload* de WAV/MP3/OGG ou URL de YouTube (via yt-dlp). Apenas transcrição + análise textual. Cenário típico de consulta presencial em que apenas a captura de áudio está disponível ou autorizada.
- **Texto puro:** cola de transcrição manual. Cenário de *dry-run* para teste de *prompt* ou análise retrospectiva de transcrições já existentes.

5.4 Prompt Especializado

O *prompt* do GPT é o componente que dá ao Insight sua especialização para saúde da mulher. A estrutura segue o padrão recomendado pela OpenAI para tarefas de classificação estruturada: *system prompt* com instruções gerais, *schema* de saída em JSON, exemplos *few-shot* e *constraint* de formato.

Os campos do JSON de saída são fixos:

- `sentiment` — `positive`, `neutral` ou `negative`.
- `risk_level` — `low`, `medium` ou `high`.
- `score` — pontuação numérica 0–10, complementar ao `risk_level`.
- `detected_signals` — lista de sinais clínicos textuais (*fear*, *crying*, *physical harm*, *anxiety*, *depression*, etc.).
- `keywords` — palavras-chave do texto que ancoram a inferência.

- `domestic_violence_signals` — *string* descritivo do padrão observado para violência doméstica, especificamente.
- `recommended_action` — sugestão de próximo passo (*review with qualified professional, schedule follow-up, no immediate action*).
- `source` — `openai_llm` ou `keyword_fallback`, indicando qual subsistema gerou a inferência.

Exemplo de saída

```
{
  "sentiment": "negative",
  "risk_level": "high",
  "score": 8,
  "detected_signals": ["fear", "crying", "physical harm"],
  "keywords": ["scared", "hurt", "help"],
  "domestic_violence_signals": "strong indicators",
  "recommended_action": "Review with qualified professional",
  "source": "openai_llm"
}
```

5.5 Fallback Rule-Based

Sistemas que dependem de API externa (OpenAI) têm modos de falha: *rate limit*, indisponibilidade, esgotamento de crédito, latência excessiva, política de bloqueio. Para garantir **degradação graciosa**, o Insight inclui um analisador *rule-based* que opera 100% offline sobre a transcrição textual.

O analisador alternativo consiste em **27 expressões regulares** ponderadas em três níveis (peso 1, 2 ou 3 conforme a severidade do sinal). Cada *match* acumula no `score` final, e *thresholds* convertem o `score` acumulado em `risk_level`. As 27 *regex* foram derivadas de literatura clínica de triagem de violência doméstica, depressão pós-parto e ansiedade gestacional, com revisão por leitor adicional do grupo.

O fluxo de fallback é transparente para o usuário:

1. Tenta chamar OpenAI primeiro; *timeout* de 30s.
2. Em sucesso, retorna JSON com `source`: `"openai_llm"`.
3. Em qualquer erro (HTTP, exceção, *rate limit*, conteúdo bloqueado), executa o analisador *rule-based* e retorna JSON com `source`: `"keyword_fallback"`, com a mesma *schema* de campos.

O campo `source` permite ao consumidor da API (por exemplo, um EHR integrado) saber a procedência da análise e calibrar a confiabilidade.

5.6 Visualização e Exportação

A UI Streamlit apresenta o resultado da análise em quatro componentes:

- **Métricas no topo:** `sentiment`, `risk_level`, `score`, modalidades utilizadas.
- **Lista de sinais detectados:** *badges* coloridos por categoria (medo, choro, agressão, ansiedade, etc.).
- **Transcrição completa** colapsável, com *timestamps* alinhados.
- **Recomendação de ação:** *box* com cor proporcional à severidade.

A análise completa pode ser exportada como JSON (para integração) ou como PDF (para registro no *wallet* clínico da paciente). Em ambos os formatos, o *disclaimer* acadêmico é incluído de forma proeminente.

5.7 Considerações Específicas para Cada Cenário

5.7.1 Consultas Ginecológicas

Sinais procurados: hesitação ao relatar sintomas íntimos, sub-relato de dor (frequente em literatura ginecológica ([Hoffmann; Tarzian, 2001](#))), tom defensivo. *Keywords* típicos: *embarrassed*, *don't want to talk, just a little bit*.

5.7.2 Pré-natal

Sinais procurados: ansiedade gestacional, medo de perda fetal, preocupação excessiva com sintomas normais. *Keywords*: *worried*, *can't sleep*, *something wrong with baby*.

5.7.3 Pós-parto

Sinais procurados: depressão pós-parto ([Howard; Khalifeh, 2020](#)), desinteresse pelo recém-nascido, anedonia, fadiga extrema desproporcional. *Keywords*: *don't feel anything*, *can't bond*, *tired all the time*.

5.7.4 Vítimas de Violência

Sinais procurados: medo, evasão de detalhes, vergonha, dano físico autodeclarado. *Keywords: scared, hurt, help, he doesn't let me.*

Atenção

O Insight **NÃO** é uma ferramenta de triagem de violência doméstica para uso real. Falsos positivos podem expor a vítima a riscos adicionais, e falsos negativos perpetuam o ciclo de violência. Em uso real, triagem de violência deve seguir protocolos validados (e.g., *Abuse Assessment Screen* ([McFarlane et al., 1992](#))) com profissional treinado.

Infraestrutura, Cloud e LGPD

Este capítulo consolida o uso de serviços em nuvem, a estratégia de Infrastructure as Code (IaC) via Terraform e as práticas de privacidade alinhadas à Lei Geral de Proteção de Dados (LGPD) adotadas no Sentinel Health. Atende aos objetivos do desafio relacionados a uso de cloud, à funcionalidade 4 (integração com serviços gerenciados em nuvem) e ao requisito implícito de privacidade para dados sensíveis.

6.1 Estratégia Multi-Cloud

A plataforma integra **três provedores de nuvem**, cada um escolhido pelo *fit* ao tipo de carga:

- **AWS:** infraestrutura computacional (EC2), armazenamento (S3), *secrets* (SSM Parameter Store), *identity* (IAM), *IaC* via Terraform.
- **OpenAI API:** LLM (gpt-5.4-nano) e ASR (whisper-1). Carga elástica, paga por *token*/segundo, sem provisão capacidade.
- **Hugging Face Hub:** distribuição pública do *checkpoint* treinado do YOLOv8m, com *model card* navegável.

A separação não é apenas técnica — também é estratégica: cada provedor responde a uma necessidade distinta sem que falha em um derrube todo o sistema. A indisponibilidade da OpenAI dispara o *fallback rule-based* do Insight (Seção 5.5); a indisponibilidade do Hugging Face não afeta runtime, apenas *cold boot* do container Surgical; a indisponibilidade da AWS afeta o *deploy* demonstrativo, mas não impede o *stack* local.

6.2 Infraestrutura como Código

O diretório terraform/ no monorepo organiza a IaC em *layers*:

- `modules/storage/` — *S3 buckets* para *assets* estáticos da *landing* e para *models* (legado; agora servido via HF Hub). Ambos com `public_access_block` ativado, `versioning` habilitado e `force_destroy=true` (para permitir `terraform destroy` limpo em demo).
- `modules/runtime/` — EC2 `t3.medium`, *Security Group* restritivo (apenas portas 80/443, SSH **NÃO** aberto), *IAM Role* com permissões mínimas, `user_data` que clona o repositório público e sobe o *stack*.
- `environments/demo/` — composição: `module.storage` + `module.runtime` + DNS opcional.

A demonstração na nuvem é **efêmera e barata**: cerca de \$0,04/hora para a EC2 `t3.medium` (*on-demand*, região `us-east-1`), tipicamente provisionada por minutos durante a gravação do vídeo demo e destruída em seguida. O `terraform destroy` remove todos os recursos limpamente, incluindo *buckets* versionados, graças ao `force_destroy`.

6.3 Acesso Administrativo via SSM Session Manager

Por padrão, instâncias EC2 expõem SSH na porta 22 — superfície de ataque comum e fonte de credenciais comprometidas. O Sentinel Health adota o padrão recomendado pela AWS para *cloud-native hardening*: **SSH desabilitado por completo no Security Group**, com acesso administrativo via SSM Session Manager.

Benefícios concretos:

- Sem chaves SSH para gerenciar/rotacionar/comprometer.
- Autenticação via IAM (com SSO, se o usuário usar AWS Identity Center).
- Auditoria nativa via CloudTrail — toda sessão registrada com identidade, comandos e *output*.
- Sem necessidade de IP público para administração (a sessão tunela via AWS backplane).

6.4 Secrets Management

A chave da API OpenAI é o *secret* crítico do Sentinel Insight. Estratégia adotada:

- **Nunca em código, nunca em `.env` commitado, nunca em `terraform.tfvars` versionado.**
- Armazenada em SSM Parameter Store como `SecureString`, no *path* `/sentinel/insight/openai_api_key`.

- O *IAM Role* da EC2 tem permissão `ssm:GetParameter` restrita a esse *path*.
- O `user_data` do EC2 faz `aws ssm get-parameter` no *boot* e injeta a variável de ambiente `OPENAI_API_KEY` no container *Insight*.
- Para *deploy* local: o usuário coloca a chave em `modules/insight/emotion-recognizer/.env`, que está em `.gitignore`.

A chave **nunca aparece em *Terraform state***, garantindo que o *state file* possa ser compartilhado em S3 com Lock via DynamoDB sem expor credenciais.

6.5 LGPD: Princípios e Práticas Aplicadas

A Lei Geral de Proteção de Dados (LGPD) (Lei nº 13.709/2018) impõe princípios específicos para tratamento de dados pessoais sensíveis — categoria à qual dados de saúde inequivocamente pertencem (art. 5º, II) ([Brasil, 2018](#)). As práticas adotadas neste protótipo:

6.5.1 Volumes Locais por Padrão

Uploads de vídeo/áudio e resultados do processamento são gravados em *volumes Docker* no *host* de *deployment*. Não há *upload* automático para *cloud storage*. O operador decide o que fazer com cada arquivo (em conformidade com a finalidade legítima da consulta).

6.5.2 TLS End-to-End

Quando o *stack* roda atrás do *reverse proxy* do *host*, o usuário configura certificado TLS via Let's Encrypt ou similar. O *snippet* `nginx/host-snippet.conf` fornecido inclui exemplos de configuração com `ssl_protocols TLSv1.2 TLSv1.3`.

6.5.3 Sem Persistência Centralizada de Dados de Paciente

Cada análise é **stateless** no servidor: o JSON resultante é entregue ao usuário e os arquivos temporários são removidos após a sessão. Em uso real, integração com EHR via API substituiria o armazenamento local, com governança de dados centralizada no EHR hospitalar.

6.5.4 Logs Sem PII

Os logs de aplicação (*uvicorn*, *Streamlit*, *nginx*) registram `job_id` (UUID v4), *timestamps* e *status*, mas **nunca** o conteúdo das transcrições ou *embeddings* de face. Logs são *stdout/stderr* do container, consumidos via `docker compose logs` para diagnóstico operacional.

6.5.5 Princípio do Mínimo Privilégio

O IAM Role da EC2 tem permissões estritamente necessárias: s3:GetObject no bucket de assets de landing (somente leitura), ssm:GetParameter no path específico do secret OpenAI. Sem permissões amplas (*) ou administrativas.

6.5.6 Princípio do Esquecimento

A arquitetura permite eliminação simples de dados em até 24h: volumes Docker removidos via docker compose down -v; snapshots EC2 expirados em janela curta; S3 lifecycle policy para expirar objects após 30 dias.

Limite de escopo do protótipo

As práticas descritas atendem o **nível de protótipo acadêmico**. Compliance LGPD real em ambiente hospitalar requer adicionalmente: contrato de operação com controller (hospital) explícito, Data Protection Impact Assessment formal, base legal específica para tratamento (art. 7º e art. 11), nomeação de DPO, e auditoria independente.

6.6 Estimativa de Custos

A Tabela 6.1 apresenta a estimativa de custos para um deploy demonstrativo de 1 hora.

Tabela 6.1: Estimativa de custos para deploy demonstrativo de 1 hora (AWS us-east-1, preços on-demand 2026).

Recurso	Custo (USD)
EC2 t3.medium (1h)	0,04
S3 assets bucket (50 MB, 1 dia)	< 0,001
Egress 1 GB (download de model + assets)	0,09
OpenAI API (30 chamadas demo)	0,05
Total demo	0,18

Custo desprezível para uso acadêmico, permitindo deploys repetidos durante a gravação do vídeo demonstrativo sem preocupação orçamentária.

Resultados e Discussão

Este capítulo consolida os resultados quantitativos e qualitativos do trabalho, apresenta a matriz de cobertura item a item do desafio, exemplos representativos de detecção, e discute criticamente as limitações observadas.

7.1 Matriz de Cobertura do Desafio

A Tabela 7.1 apresenta a cobertura agregada do desafio. A matriz detalhada item a item — com 23 itens individuais, evidência textual de atendimento e mapeamento para módulo responsável — está disponível em formato interativo em `landing/coverage.html` dentro da plataforma e em formato *markdown* em `docs/CHALLENGE_COVERAGE.md` no repositório.

Tabela 7.1: Cobertura do Tech Challenge Fase 4 pelo Sentinel Health (agregada por seção do enunciado).

Seção do Enunciado	Atendidos	Mínimo	Roadmap
Funcionalidades (escolha ≥ 2)	3	2	1
Objetivos (escolha ≥ 3)	5	3	0
Requisito 1 — Análise de Vídeo	6	7	1
Requisito 2 — Análise de Áudio	4	4	0
Entregáveis Técnicos	3	3	0
Total	21	—	2

A escolha do grupo **excede os mínimos** nas duas seções com opção (Funcionalidades e Objetivos) e **cobre integralmente** o Requisito de Áudio e os Entregáveis. No Requisito de Vídeo, 6 dos 7 itens são atendidos — o item restante (análise de fisioterapia pós-parto) está declarado em *roadmap* com tecnologia-alvo (*pose estimation* via MediaPipe ou MoveNet).

7.2 Resultados Quantitativos do Surgical

A Tabela 7.2 sumariza os resultados quantitativos do detector YOLOv8m de sangramento. As métricas detalhadas por fase de treino e por *threshold* estão no Capítulo 4 (Tabelas 4.1 e 4.2).

Tabela 7.2: Resultados consolidados do Sentinel Surgical (v3 *fine-tuned* em GynSurg, *threshold* 0,30, conjunto de validação de 20 cliques com 1.800 *frames*).

Métrica	Valor
Taxa de detecção (<i>recall</i> por clipe)	91,72%
Taxa de FP (<i>precision</i> complementar)	13,44%
mAP@0.5 (médio sobre validação)	0,684
Tamanho do modelo (best . pt)	50 MB
Tempo de inferência (CPU, 720p)	85 ms/frame
Tempo de inferência (CPU, 240p)	22 ms/frame
Hardware testado	Intel Xeon Platinum 8259CL (EC2 t3.medium)

7.2.1 Discussão da Taxa de FP

A taxa de FP de 13,44% — embora superior ao desejado — foi escolhida deliberadamente. Conforme discutido na Seção 4.4, em sala cirúrgica o custo de falsos negativos (perder um sangramento real) é qualitativamente maior do que o de falsos positivos (alertar quando não há). O *threshold* 0,30 favorece sensibilidade sobre especificidade.

Análise qualitativa dos *frames* que geram FP mostra três padrões dominantes:

- 1. **Iluminação dramática** criando reflexos vermelhos em tecido normal.
- 2. **Sangue residual de cauterização** (não sangramento ativo) sendo confundido com sangramento ativo.
- 3. **Tecido vascularizado** (e.g., trompa de falópio) sob luz específica.

Os três padrões são endereçáveis em iterações futuras com: (a) augmentação de dados com variação de iluminação no treino, (b) anotação explícita de classes `residual_blood` vs `active_bleeding`, e (c) ampliação do conjunto de anotação com casos representativos dos três padrões.

7.3 Resultados Qualitativos do Insight

O Insight foi testado em 12 áudios sintéticos representativos dos quatro cenários do Requisito de Áudio (3 áudios por cenário). A Tabela 7.3 mostra o resultado da análise.

O LLM (GPT-5.4-nano) acertou todos os 12 casos; o *fallback rule-based* acertou 10/12 (os 2 erros foram em consultas ginecológicas e pós-parto, casos em que sinais são mais sutis e

Tabela 7.3: Avaliação qualitativa do Sentinel Insight em 12 áudios sintéticos. *Ground truth* estabelecido pelo grupo a partir do roteiro do áudio gerado.

Cenário	LLM concorda c/ <i>ground truth</i>	Fallback concorda
Consulta ginecológica	3/3	2/3
Pré-natal (ansiedade)	3/3	3/3
Pós-parto (depressão)	3/3	2/3
Vítima de violência	3/3	3/3
Total	12/12	10/12

menos diretamente vocabulários — situações em que o LLM tem clara vantagem por capturar pragmática e contexto). Esse resultado valida a estratégia de **primário LLM, fallback rule-based para degradação graciosa**.

Atenção

Esses 12 áudios são **sintéticos** (roteirizados pelo grupo) e **em inglês**. A avaliação serve como prova de conceito de que o *pipeline* funciona ponto-a-ponto, não como validação clínica em áudio real em português. Validação real exigiria estudo prospectivo com áudio gravado em consulta real, ética em pesquisa aprovada, e *ground truth* estabelecido por profissional treinado.

7.4 Exemplo Representativo: Análise de Vídeo de Sangramento

A Tabela 7.4 apresenta um exemplo de saída do Surgical para um clipe de 8 segundos do GynSurg com sangramento ativo a partir do *frame* 90.

Tabela 7.4: Excerto do JSON de detecções para um clipe representativo. Resumo: `total_detections=37,duration=8s,detections_by_class={blood: 37}`.

Frame	Timestamp (s)	Confiança	Bounding Box
88	2.94	0.31	[0.42, 0.51, 0.18, 0.14]
91	3.04	0.58	[0.41, 0.50, 0.21, 0.16]
94	3.14	0.72	[0.40, 0.50, 0.23, 0.18]
...	...	...	...
220	7.34	0.91	[0.38, 0.48, 0.28, 0.22]

O modelo começou a detectar no *frame* 88 (poucos *frames* antes do início do sangramento real conforme *ground truth* no *frame* 90), com confiança ascendente conforme a área de sangue se ampliou. Esse padrão — confiança ascendente acompanhando severidade — é comportamento desejado para o uso clínico (alerta precoce e proporcional).

7.5 Exemplo Representativo: Análise de Áudio com Sinais de Violência

A saída JSON do Insight para um áudio sintético com roteiro de vítima de violência (*ground truth*: `risk_level=high`) está reproduzida na Seção 5.4 (Capítulo 5). O LLM identificou os três sinais críticos (*fear*, *crying*, *physical harm*) e produziu a *recommended_action* apropriada (*Review with qualified professional*). O *fallback rule-based*, para o mesmo áudio, identificou `score=7` (vs 8 do LLM) e `risk_level=high` — degradação aceitável.

7.6 Bug Fixes Notáveis Durante o Desenvolvimento

Três classes de *bug* encontradas durante *testing* merecem registro por aplicabilidade educacional:

7.6.1 yt-dlp e o Player do YouTube

A primeira versão do *endpoint* `/api/video/url` do Surgical pedia ao yt-dlp formato `best[height<=720]`, que força o caminho *DASH*: *streams* separados de áudio/vídeo, deobfuscação de *signature* do *player* JS, e *merge* via *ffmpeg*. Esse caminho é frágil — quebra a cada atualização do *player* do YouTube. **Fix**: trocar para `worst[ext=mp4]` (*stream* progressivo único, sem deobfuscação) — espelhando o padrão funcional já em uso no módulo Insight.

7.6.2 Cloudflare 524 por Bloqueio do Event Loop

A segunda versão do mesmo *endpoint* colocou o yt-dlp em *BackgroundTasks* do FastAPI, mas declarado como `async def`. O `subprocess.run(yt-dlp, ...)` é síncrono e bloqueia o *event loop* do FastAPI, congelando o *endpoint* `/api/video/status/{job_id}` que o *polling* do *frontend* consome. Após 100s, Cloudflare cortava com 524 e o *frontend* quebrava ao tentar parsear HTML como JSON. **Fix**: trocar `async def` por `def sync`; FastAPI *BackgroundTasks* então roda em *thread pool*, mantendo o *loop* livre.

7.6.3 License Detection do GitHub

A primeira versão do arquivo `LICENSE` continha um bloco *ACADEMIC USE NOTICE* anexo após o texto canônico da MIT License. O *parser* `licensee` do GitHub usa *similarity* contra texto canônico com *threshold* de 98%, e o anexo baixava a similaridade abaixo desse limite — o repositório aparecia como *License: Other* em vez de *License: MIT*. **Fix**: separar em `LICENSE` (MIT pura) e `ACADEMIC_USE.md` (anexo informativo), com *cross-link* no README.

7.7 Limitações Conhecidas

1. **Validação clínica ausente:** nenhum dos modelos passou por validação prospectiva. Os 13% de FP do Surgical e os 100% de acerto do Insight foram medidos em conjuntos de pesquisa, não em uso real.
2. **Tamanho do conjunto de validação do Surgical:** 20 cliques (1.800 *frames*) é pequeno. Variância de generalização para outros tipos de procedimento ginecológico não foi caracterizada.
3. **Idioma do Insight:** a avaliação dos 12 áudios foi em inglês. Em português, espera-se queda de desempenho do *fallback rule-based* (porque as *regex* foram derivadas de literatura em inglês); o LLM degrada menos por capacidade multilíngue nativa do GPT-5.4-nano.
4. **Bias de *datasets*:** CholecSeg8k e GynSurg representam pacientes adultos majoritariamente europeus em centros de excelência. Generalização para outras demografias e contextos hospitalares precisa ser validada.
5. **Dependência de API externa:** Insight *prime* requer OpenAI; o fallback degrada graciosamente, mas com perda de qualidade documentada.

7.8 Discussão Sobre Uso Responsável

O Sentinel Health é desenhado como **ferramenta de apoio**, não substituto da decisão clínica. As principais decisões de design refletem essa premissa:

- Toda saída é **revisável**: o JSON detalha confianças, *keywords*, *frames* específicos. O profissional pode auditar a cadeia de inferência.
- Sem **ação automatizada**: o sistema não dispara notificação, atualização de EHR ou alerta autônomo. Toda ação é mediada por humano.
- **Disclaimer acadêmico** é exibido em todos os pontos de saída: UI, JSON, PDF de relatório, *README*, *landing page*, apresentação. A natureza de protótipo é inequívoca.
- Em produção, requereria **retreinamento contínuo** com *ground truth* corrigido pelo profissional revisor — o *loop* de melhoria descrito na Seção 4.6 aponta nessa direção.

Conclusões e Roadmap

8.1 Síntese do Trabalho

Este trabalho apresentou o **Sentinel Health**, uma plataforma multimodal de IA para monitoramento contínuo da saúde da mulher, desenvolvida como entrega do Tech Challenge da Fase 4 do curso de Pós-Graduação em Inteligência Artificial para Devs da FIAP.

As contribuições principais foram:

1. **Detector YOLOv8m de sangramento cirúrgico** (*Sentinel Surgical*) treinado em três fases sobre CholecSeg8k + GynSurg, com **91,72% de detecção** e **13,44% de falsos positivos**, distribuído publicamente no Hugging Face Hub com *model card* profissional.
2. **Pipeline multimodal de análise emocional** (*Sentinel Insight*) combinando DeepFace, Whisper e GPT-5.4-nano, cobrindo integralmente os quatro cenários do Requisito de Áudio (ginecológica, pré-natal, pós-parto, vítimas de violência) com *fallback rule-based* de 27 expressões regulares para degradação graciosa.
3. **Plataforma integrada** com nginx *reverse proxy*, *landing page* institucional, página de cobertura interativa, apresentação *reveal.js* embutida, *IaC* via Terraform e três variantes de *deployment* (local, atrás de proxy do *host*, AWS).
4. **Cobertura de 21 dos 23 itens** do enunciado do desafio, com os 2 itens restantes declarados explicitamente em *roadmap* com tecnologia-alvo identificada.
5. **Práticas de privacidade** alinhadas à LGPD: *secrets* em SSM Parameter Store, SSH desabilitado em favor de SSM Session Manager, S3 com *block public access*, sem persistência centralizada de dados de paciente.
6. **Código-fonte aberto** sob licença MIT em github.com/Zagari/sentinel-health (público), com documentação completa, testes de *smoke*, *model card* no Hugging Face Hub e este relatório técnico.

8.2 Atendimento ao Desafio

A Tabela 8.1 consolida o atendimento aos requisitos do enunciado.

Tabela 8.1: Atendimento ao Tech Challenge Fase 4 — síntese final.

Item do Enunciado	Status
Funcionalidades — análise de vídeos clínicos	Atendido (Surgical)
Funcionalidades — processamento de gravações de voz	Atendido (Insight)
Funcionalidades — integração com serviços de nuvem	Atendido (AWS + OpenAI + HF)
Funcionalidades — detecção de anomalias em sinais vitais	<i>Roadmap</i>
Objetivos — risco materno-ginecológico	Atendido (Surgical)
Objetivos — violência doméstica	Atendido (Insight)
Objetivos — bem-estar psicológico	Atendido (Insight)
Objetivos — cloud para processamento	Atendido (Multi-cloud)
Objetivos — anomalias em tempo real	Atendido (<i>near real-time</i>)
Req. 1 — Análise de Vídeo (cirurgias)	Atendido
Req. 1 — Análise de Vídeo (consultas)	Atendido (via Insight)
Req. 1 — Análise de Vídeo (triagem violência)	Atendido (via Insight)
Req. 1 — Análise de Vídeo (fisioterapia)	<i>Roadmap</i>
Req. 1 — YOLOv8 customizado	Atendido (<i>bleeding</i>)
Req. 1 — Relatórios automáticos especializados	Atendido (JSON estruturado)
Req. 1 — Alertas para casos de violência	Atendido (via Insight)
Req. 2 — Consultas ginecológicas	Atendido
Req. 2 — Acompanhamento pré-natal	Atendido
Req. 2 — Consultas pós-parto	Atendido
Req. 2 — Atendimento a vítimas de violência	Atendido
Entregável — Repositório Git	Atendido (github.com/Zagari/sentinel-health)
Entregável — Relatório técnico	Este documento
Entregável — Vídeo demonstrativo (até 15 min)	Atendido

8.3 Roadmap

As frentes não cobertas e oportunidades de evolução estão organizadas em quatro grupos.

8.3.1 Sentinel Motion

Objetivo: análise de movimento em fisioterapia pós-parto via *pose estimation* (MediaPipe, MoveNet ou OpenPose). Fecha o último item do Requisito de Vídeo.

Esforço estimado: 40–60 horas. Inclui prototipagem com biblioteca de *pose estimation*, definição de exercícios-alvo (Kegel guiado, alongamentos pélvicos, recuperação diastasis recti), métricas de simetria/amplitude/duração, e UI para feedback em tempo real.

Dataset-alvo: INTERACT ([INTERACT Project, 2022](#)) ou geração própria com vídeos de fisioterapia gravados em colaboração com clínica parceira (sob ética em pesquisa apropriada).

8.3.2 Sentinel VitalSigns

Objetivo: detecção de anomalias em sinais vitais específicos — pressão arterial em gestantes (pré-eclâmpsia), batimentos fetais (taquicardia/bradicardia fetal). Fecha a quarta funcionalidade opcional do enunciado.

Esforço estimado: 40–80 horas. Inclui ingestão de dados de monitores (formato HL7/FHIR ou CSV de *wearables*), detecção de anomalias via *moving window* + *z-score* ou modelo de séries temporais leve (ARIMA, Prophet, ou *Isolation Forest*), e integração com alertas.

8.3.3 Sentinel Realtime

Objetivo: *streaming* síncrono ao vivo, eliminando a latência atual (*near real-time*, ≤ 1 minuto entre captura e alerta) em favor de processamento contínuo *frame-a-frame* (*streaming*).

Esforço estimado: 60–100 horas. Inclui adaptação do *backend* para WebSocket ou WebRTC, otimização de *inference latency* (*quantization* INT8, TensorRT em GPU), *buffer ring* de *frames*, e tratamento de *back-pressure*.

8.3.4 Sentinel Pose

Objetivo: análise de linguagem corporal indicativa de abuso (postura defensiva, evitação visual, microexpressões), complementando a análise atual de face + voz do Insight.

Esforço estimado: 30–50 horas. Combinação de *pose estimation* com classificador de padrões aprendido em *dataset* de comportamento clinicamente anotado. Requer *dataset* específico (não há *public dataset* pronto para essa tarefa) — provável colaboração com instituição de pesquisa.

8.4 Recomendações para Evolução Responsável

Para qualquer evolução em direção a uso clínico real, recomendamos:

1. **Validação prospectiva** em estudo clínico com aprovação ética, *ground truth* estabelecido por profissional treinado, e métricas reportadas com intervalos de confiança.
2. **Calibração de *thresholds*** por instituição: cada centro tem população, equipamentos e padrões diferentes; um *threshold* ótimo para um pode não ser para outro.
3. **Monitoramento contínuo de *drift***: o desempenho do modelo varia conforme mudam práticas cirúrgicas, equipamentos de captura, e demografia. Monitorar métricas em produção, recalibrar trimestralmente.
4. **Auditoria de viés**: medir desempenho por subgrupo demográfico (faixa etária, etnia, comorbidades), e corrigir disparidades via *re-training* balanceado ou ajuste de *threshold* por grupo.
5. **Plano de descontinuação**: qualquer sistema de IA em saúde deve ter *exit strategy* — como o serviço continua se o modelo precisar ser desligado por questão regulatória ou de desempenho.

8.5 Agradecimentos

Agradecemos à FIAP pela estrutura do curso, ao corpo docente pelos conteúdos das fases anteriores que pavimentaram este trabalho, à comunidade *open-source* pelos *frameworks* (Ultralytics, DeepFace, OpenAI *whisper-1*, FastAPI, Streamlit, Terraform) que viabilizaram a integração rápida, e ao Hugging Face Hub pela infraestrutura gratuita de distribuição de modelos.

Encerramento

O Sentinel Health é um **protótipo acadêmico**. As decisões reais sobre saúde da mulher devem permanecer onde sempre estiveram: nas mãos de profissionais qualificados, com escuta empática e tempo suficiente para compreender cada paciente como indivíduo. Que ferramentas como esta sejam, no melhor cenário, multiplicadoras da atenção humana — nunca substitutas.

Referências Bibliográficas

WORLD HEALTH ORGANIZATION. **Women's health: Key facts**. [S. l.: s. n.], 2024. <https://www.who.int/news-room/fact-sheets/detail/women-s-health>. Acessado em maio de 2026.

KLETZ, Sabrina; SCHOEFFMANN, Klaus; HUSSLEIN, Heinrich. Identifying surgical instruments in laparoscopy using deep learning instance segmentation. **IEEE Access**, v. 7, 2019.

RADFORD, Alec *et al.* **Robust Speech Recognition via Large-Scale Weak Supervision**. [S. l.: s. n.], 2022. OpenAI Technical Report. <https://cdn.openai.com/papers/whisper.pdf>.

SINGHAL, Karan; AZIZI, Shekoofeh *et al.* Large language models encode clinical knowledge. **Nature**, v. 620, p. 172–180, 2023.

BALTRUŠAITIS, Tadas; AHUJA, Chaitanya; MORENCY, Louis-Philippe. Multimodal Machine Learning: A Survey and Taxonomy. **IEEE Transactions on Pattern Analysis and Machine Intelligence**, v. 41, n. 2, p. 423–443, 2019.

SNOEK, Cees G. M.; WORRING, Marcel; SMEULDERS, Arnold W. M. Early versus late fusion in semantic video analysis. *In*: PROCEEDINGS of the 13th annual ACM international conference on Multimedia. [S. l.: s. n.], 2005. p. 399–402.

REDMON, Joseph *et al.* You Only Look Once: Unified, Real-Time Object Detection. *In*: PROCEEDINGS of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). [S. l.: s. n.], 2016. p. 779–788.

JOCHER, Glenn; CHAURASIA, Ayush; QIU, Jing. **Ultralytics YOLOv8**. [S. l.: s. n.], 2023. <https://github.com/ultralytics/ultralytics>. Versão 8.0+, acessado em maio de 2026.

SERENGIL, Sefik Ilkin; OZPINAR, Alper. LightFace: A Hybrid Deep Face Recognition Framework. *In*: INNOVATIONS in Intelligent Systems and Applications Conference (ASYU). [S. l.: s. n.], 2020. p. 23–27.

BUOLAMWINI, Joy; GEBRU, Timnit. Gender shades: Intersectional accuracy disparities in commercial gender classification. **Proceedings of Machine Learning Research**, v. 81, p. 77–91, 2018.

SINGHAL, Karan; TU, Tao *et al.* Towards Expert-Level Medical Question Answering with Large Language Models. **arXiv preprint arXiv:2305.09617**, 2023.

Ji, Ziwei *et al.* Survey of Hallucination in Natural Language Generation. **ACM Computing Surveys**, v. 55, n. 12, p. 1–38, 2023.

HONG, W.-Y. *et al.* CholecSeg8K: A Semantic Segmentation Dataset for Laparoscopic Cholecystectomy Based on Cholec80. **arXiv preprint arXiv:2012.12453**, 2020.

GYNSURG DATASET CONTRIBUTORS. **GynSurg: A laparoscopic gynecological surgery video dataset**. [S. l.: s. n.], 2023. Dataset utilizado em treinamento de modelos de visão computacional cirúrgica. Anotações para detecção de sangramento adicionadas pelo grupo.

GOODFELLOW, Ian J. *et al.* Challenges in representation learning: A report on three machine learning contests. *In*: INTERNATIONAL Conference on Neural Information Processing (ICONIP). [S. l.: s. n.], 2013. p. 117–124.

LIU, Karen A.; MAGER, Natalie A. Dipietro. Women's involvement in clinical trials: Historical perspective and future implications. **Pharmacy Practice**, v. 14, n. 1, 2016.

HOWARD, Louise M.; KHALIFEH, Hind. Perinatal mental health: a review of progress and challenges. **World Psychiatry**, v. 19, n. 3, p. 313–327, 2020.

STEVENS, Brett P.; SALMONS, Heather I.; GOLDENBERG, Robert L. Hemorrhage during minimally invasive gynecologic surgery. **Obstetrics and Gynecology Clinics of North America**, v. 46, n. 1, p. 25–35, 2019.

HOFFMANN, Diane E.; TARZIAN, Anita J. The girl who cried pain: A bias against women in the treatment of pain. **Journal of Law, Medicine & Ethics**, v. 29, p. 13–27, 2001.

MCFARLANE, Judith *et al.* Assessing for abuse during pregnancy: severity and frequency of injuries and associated entry into prenatal care. **JAMA**, v. 267, n. 23, p. 3176–3178, 1992.

BRASIL. **Lei Geral de Proteção de Dados Pessoais (Lei n. 13.709/2018)**. [S. l.: s. n.], 2018. http://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/L13709.htm. Acessado em maio de 2026.

INTERACT PROJECT. **INTERACT: A dataset for physical therapy motion analysis**. [S. l.: s. n.], 2022. Dataset de referência para análise de movimento em fisioterapia. Citação ilustrativa para roadmap.